UNIVERSIDADE FEDERAL DE OURO PRETO
INSTITUTO DE CIÊNCIAS EXATAS E BIOLÓGICAS
DEPARTAMENTO DE ESTATÍSTICA

MICHEL LIMA DE OLIVEIRA

RELATÓRIO - ANÁLISE FATORIAL

OURO PRETO
2025

MICHEL LIMA DE OLIVEIRA

RELATÓRIO - ANÁLISE FATORIAL

Trabalho apresentando à disciplina de Estatística Multivariada do curso de Estatística da Universidade Federal de Ouro Preto (UFOP), ministrada pelo Prof. Thiago Martins Pereira.

Matrícula: 22.2.4052

OURO PRETO
2025

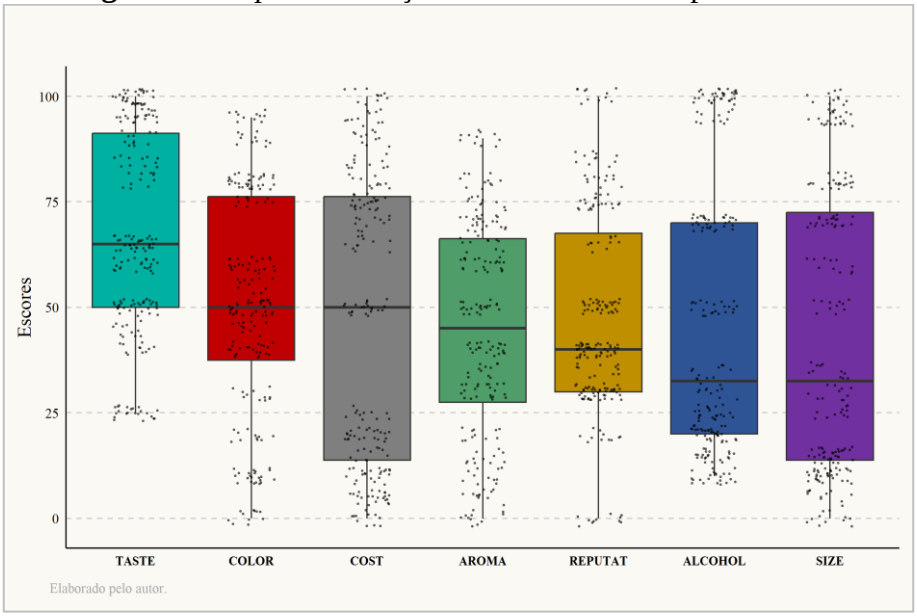
1. **INTRODUÇÃO**

O relatório referente ao trabalho final da disciplina Estatística Multivariada consiste em realizar uma Análise Fatorial Exploratória, a partir da base de dados AnaFatBeer.txt. Esse conjunto foi obtido na página desta disciplina (EST014), no *Moodle* UFOP, e possui 231 observações distribuídas em 9 (nove) variáveis: GROUP, SES, COST (custo do *pack*), SIZE (volume de cerveja no *pack*), ALCOHOL (percentagem de álcool na bebida), REPUTAT (reputação da marca), COLOR (cor da bebida), AROMA (aroma da bebida) e TASTE (sabor da bebida). Ressalta-se que foram excluídas da análise fatorial as variáveis GROUP e SES por representarem categorias interpretáveis independentemente. Adicionalmente, os 11 valores ausentes (NA) identificados na variável AROMA foram removidos para evitar distorções nos resultados e garantir a robustez das análises. Isto posto, o banco resultou em 220 observações e 7 variáveis.

O planejamento de uma Análise Fatorial exige a verificação da adequabilidade da base de dados. Nesse sentido, avalia-se o tamanho da amostra, existência de correlações significativas e checagem do critério de Kaiser-Meyer-Olkin (KMO). Além disso, é necessário determinar o método de extração dos fatores (componentes principais, fatores principais ou máxima verossimilhança), o número de fatores (critério de Kaiser, *screeplot* ou variância acumulada) e o tipo de rotação dos fatores a ser aplicado (varimax, quartimax ou orthomax). Essa etapa de verificação é fundamental, uma vez que diversas características estatísticas da Análise Fatorial dependem da validade desses processos.

O gráfico de *boxplots* que está sendo representado pela Figura 1, a seguir, explora importantes medidas sobre as variáveis objetos de estudo. Constata-se, nesse sentido, que a variável TASTE apresentou a maior mediana entre as demais, indicando avaliações positivas dos consumidores em relação ao sabor da bebida. Em contrapartida, as variáveis ALCOHOL e SIZE exibiram as menores medianas, sugerindo menor satisfação. Observa-se, também, que as variáveis COST e SIZE apresentaram alta variabilidade nas avaliações. Além disso, verificou-se a presença de valores *outliers* em todas as categorias, o que pode indicar avaliações extremas e/ou erros de medição.

Figura 1: *Boxplot*: avaliação dos consumidores por variável



Fonte: Dados fornecidos pelo *moodle* UFOP, 2025.

Como buscamos identificar as estruturas subjacentes, ou seja, as variáveis latentes que explicam os padrões de correlação entre as variáveis observadas, examinaremos a estrutura do banco de dados para definir o método de correlação mais adequado. Conforme demonstrado na Tabela 1, as variáveis analisadas apresentam mais de 8 (oito) categorias cada, indicando que a correlação de Pearson representa a escolha metodológica mais adequada em detrimento da correlação policórica.

Tabela 1: Análise Exploratória dos Dados

Valores Ausentes (NAs) e Categorias

VARIÁVEL	VALORES AUSENTES	CATEGORIAS
COST (custo do pack)	0	15
SIZE (volume de cerveja no pack)	0	14
ALCOHOL (percentagem de álcool na bebida)	0	10
REPUTAT (reputação da marca)	0	11
COLOR (cor da bebida)	0	13
AROMA (aroma da bebida)	11	16
TASTE (sabor da bebida)	0	11

Elaborado pelo autor.

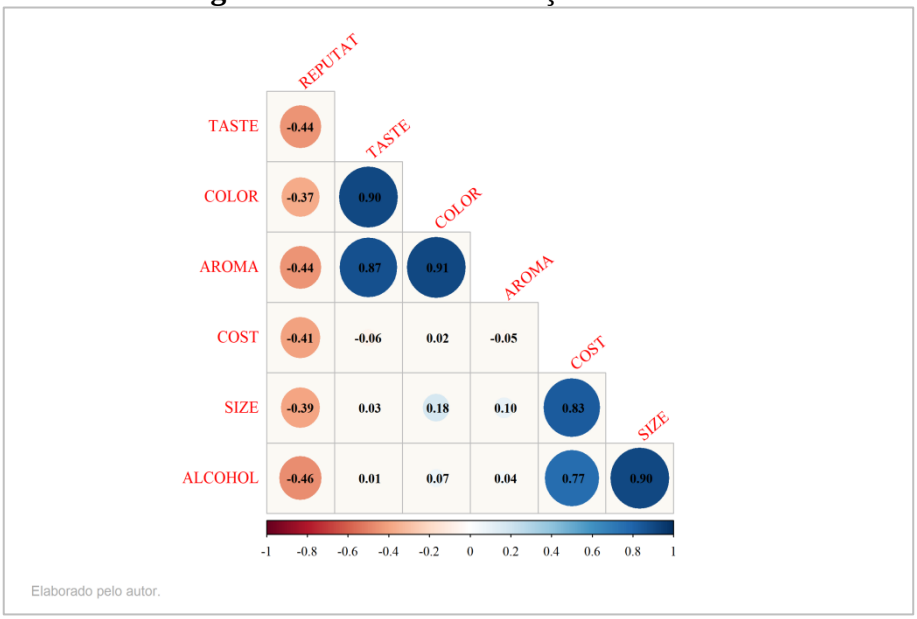
Fonte: Dados fornecidos pelo *moodle* UFOP, 2025.

Para determinar o método de extração dos fatores, avalia-se a normalidade multivariada da matriz dos dados, ou seja, se a amostra provém ou não de uma distribuição normal multivariada. Nesse caso, os testes de normalidade Shapiro Wilk e Royston

multivariado resultaram em pequenos p-valores iguais a 2.2e-16 e 6.942554e-37, respectivamente. Esses resultados sugerem a rejeição da hipótese de normalidade multivariada ao nível de 5% de significância, indicando que os dados não provém de uma distribuição normal multivariada. Considerando que a suposição de normalidade foi violada, o método de extração dos fatores ocorrerá por meio das componentes principais ou fatores principais

A verificação inicial da adequabilidade da amostra pode ser feita por meio da matriz de correlação de Pearson (ver Figura 2), na qual se observam três padrões distintos de associação entre as variáveis. Nesse sentido, constata-se a existência de grupos de variáveis altamente correlacionadas entre si e não-correlacionadas com o outro grupo. No grupo 1, temos as seguintes variáveis correlacionadas entre si: COLOR, TASTE e AROMA; no grupo correlacionado 2, temos: SIZE, COST e ALCOHOL; já no grupo 3 temos a variável REPUTAT que não se correlaciona com nenhuma outra variável.

Figura 2: Matriz de Correlação de Pearson



Fonte: Dados fornecidos pelo *moodle* UFOP, 2025.

Essa estrutura correlacional sugere a existência de fatores[1] latentes subjacentes aos grupos identificados. Contudo, a análise da matriz de correlações por si só não permite verificar a estrutura subjacente (informação comum entre as variáveis: padrão oculto) das avaliações. Para superar essas limitações e investigar adequadamente a estrutura dimensional dos dados, será aplicado a Análise Fatorial Exploratória (AFE).

[1] Fator se refere a um conjunto de variáveis fortemente correlacionadas, representando uma dimensão nos dados.

O primeiro passo para aplicar a AFE é verificar se a utilização da análise fatorial tem validade para nossos dados. Para isso, podemos utilizar dois métodos: o critério de Kaiser-Meyer-Olkin e o Teste de Esfericidade de Bartlett. O critério de KMO indica a proporção de variância em suas variáveis que pode ser causada por fatores subjacentes. Esse método avalia a adequabilidade dos dados à análise fatorial considerando a correlação entre as variáveis. Nesse caso, valores maiores que 0,5 são considerados aceitáveis.

Para medir a adequação da amostra, foi aplicado o teste KMO, que calcula o coeficiente MSA (*Measure of Sampling Adequacy*) tanto para cada variável individualmente quanto para o conjunto de dados como um todo (*Overall* MSA). O resultado do índice global (*Overall*) foi igual a 0.67, indicando que a adequabilidade da amostra é boa para realizarmos uma AFE. Além disso, todas as variáveis apresentaram valores MSA acima de 0.5 (regular), sugerindo que também são adequadas à análise fatorial (ver Tabela 2).

Tabela 2: Critério de Kaiser-Meyer-Olkin (KMO)

Análise Fatorial Exploratória

VARIÁVEL	MSA[1,2]
COST (custo do pack)	0.78
SIZE (volume de cerveja no pack)	0.55
ALCOHOL (percentagem de álcool na bebida)	0.63
REPUTAT (reputação da marca)	0.76
COLOR (cor da bebida)	0.59
AROMA (aroma da bebida)	0.80
TASTE (sabor da bebida)	0.68
KMO Geral	0.67

[1] KMO/MSA: 0,80 - 1,00 = Excelente

[2] KMO/MSA: 0,00 - 0,50 = Insuficiente

Elaborado pelo autor.

Fonte: Dados fornecidos pelo *moodle* UFOP, 2025.

Por sua vez, o teste estatístico de esfericidade de Bartlett avalia se a matriz de correlação entre as variáveis é significativamente diferente da matriz identidade. Esse processo é necessário, porque as matrizes identidades possuem variáveis não correlacionadas. A hipótese nula do teste diz que a matriz de correlação é uma matriz identidade, indicando que não há correlação significativa entre as variáveis para aplicação da técnica multivariada. Por outro lado, se o teste resultar que a matriz é diferente da identidade, significa que existe correlação suficiente para aplicação da técnica multivariada.

A viabilidade da análise fatorial foi avaliada mediante o teste de Bartlett (*cortest.bartlett*), que verifica a adequação da estrutura de correlações dos dados. No nosso caso, o teste de esfericidade resultou em um p-valor próximo de zero, permitindo rejeitar a hipótese nula ao nível de 5% de significância. Isso significa que a matriz de correlação não é a identidade, ou seja, que existe correlação suficiente para aplicação da técnica multivariada.

Após importantes análises em torno dos dados, o passo agora é determinar o número de fatores. O fator pode ser considerado um agrupamento de variáveis que captam o comportamento das variáveis do conjunto original. No nosso caso, temos um conjunto com 7 (sete) variáveis e desejamos descobrir alguns fatores (novas variáveis) que expliquem os dados. Ou seja, queremos identificar uma quantidade relativamente pequena de fatores que representem o comportamento conjunto das variáveis originais interdependentes.

Isto posto, deseja-se estimar a quantidade de fatores a ser utilizado. Entretanto, uma decisão incorreta pode acarretar na superestimação ou subestimação de fatores. A superestimação aumenta a complexidade do modelo e dificulta sua interpretação, enquanto a subestimação gera a existência de fatores com pouco significado teórico. Existem técnicas para retenção de fatores, tais como: critério de Kaiser-Guttman, *screeplot*, variância acumulada, entre outros.

Os fatores foram obtidos (ou extraídos) aplicando o critério de Kaiser com a matriz de correlações amostral, conforme abordado e exemplificado em sala de aula. Essa técnica retém à análise o número de fatores correspondente ao número de autovalores maiores do que um. Nesse sentido, o critério adotado resultou na retenção de dois fatores: Fator 1 e Fator 2 (ver Tabela 3). Além disso, a avaliação da matriz de resíduos, que apresentou valores próximos de zero, valida a adequação do modelo com dois fatores.

Tabela 3: Matriz de Autovalores e Variâncias

FATORES	AUTOVALOR	% DA VARIANCIA	% ACUMULADA DA VARIANCIA
Fator 1	3.3129	47.3270	47.3270
Fator 2	2.6158	37.3688	84.6958
Fator 3	0.5746	8.2090	92.9048
Fator 4	0.2399	3.4269	96.3316
Fator 5	0.1345	1.9208	98.2524
Fator 6	0.0854	1.2206	99.4730
Fator 7	0.0369	0.5270	100.0000

Elaborado pelo autor.

Fonte: Dados fornecidos pelo *moodle* UFOP, 2025.

Os dois fatores foram extraídos utilizando o método das componentes principais. Esse método consiste em formar combinações lineares das variáveis observadas e é considerado adequado por não exigir a normalidade multivariada da matriz dos dados. Após a extração, construiu-se a matriz L (ver Tabela 4), que apresenta as correlações entre variáveis e fatores, as comunalidades (variância compartilhada) e as especificidades (variância única de cada variável). Adotou-se o limiar de 0,40 para cargas fatoriais, critério recomendado para amostras com n = 220. Variáveis que apresentaram cargas superiores a esse valor foram consideradas estatisticamente significativas na composição dos fatores.

Tabela 4: Matriz L

Cargas Fatoriais, Comunalidades e Especificidades

VARIÁVEL	FATOR 1	FATOR 2	COMUNALIDADES	ESPECIFICIDADES
COST (custo do pack)	−0.5502	0.7344	0.8420	0.1580
SIZE (volume de cerveja no pack)	−0.6674	0.6753	0.9013	0.0987
ALCOHOL (percentagem de álcool na bebida)	−0.6320	0.6995	0.8887	0.1113
REPUTAT (reputação da marca)	0.7354	−0.0709	0.5458	0.4542
COLOR (cor da bebida)	−0.7605	−0.5760	0.9101	0.0899
AROMA (aroma da bebida)	−0.7360	−0.6137	0.9184	0.0816
TASTE (sabor da bebida)	−0.7103	−0.6464	0.9223	0.0777
Variância	3.3129	2.6158	5.9287	-
% Variância	47.3270	37.3688	84.6958	-

Elaborado pelo autor.

Fonte: Dados fornecidos pelo *moodle* UFOP, 2025.

A variável REPUTAT apresenta a menor comunalidade (0,5458), indicando que o modelo possui um bom ajuste para a maioria das variáveis, com alta capacidade explicativa. Além disso, constata-se a presença de inúmeras variáveis com cargas cruzadas (fatores significativos e com comunalidade alta), são elas: COST, SIZE, ALCOHOL, COLOR, AROMA e TASTE. Por fim, os índices de especificidades revelam a parcela não explicada pelo modelo considerando cada variável.

Embora a matriz de fatores revele as relações entre os fatores e as variáveis observadas, sua interpretação costuma ser desafiadora, já que a maior parte dos fatores aparece correlacionada com diversas variáveis. Para simplificar essa análise, aplica-se a rotação fatorial, que é um artifício para melhorar a distinção das relações encontradas e tornar a estrutura mais simples. Entre os métodos de rotação ortogonal e oblíqua, o processo varimax (ortogonal) destaca-se como o mais utilizado. Esse processo minimiza o número de variáveis

com cargas elevadas em um mesmo fator, facilitando sua interpretabilidade. Como resultado, os fatores obtidos são não correlacionados. Já na rotação oblíqua, os eixos não mantêm ângulos retos, gerando fatores correlacionados (MALHOTRA, 2001).

Para otimizar a estrutura fatorial, aplicou-se a rotação ortogonal Varimax, que produz uma matriz simplificada (n×m) com cargas fatoriais polarizadas próximo a 0 (ausência de relação) ou 1 (alta correlação), facilitando a identificação de padrões entre fatores e variáveis (CARRER, 2000). Os resultados apontam para dois componentes principais: o Fator 1 (43,1% da variância) está fortemente associado aos atributos sensoriais, como a cor, aroma e sabor da bebida: (COLOR: -0,952, AROMA: -0,958 e TASTE: -0,960), já o Fator 2 (41,6% da variância) está vinculado à características quantitativas, como o preço, volume e percentagem de álcool: (COST: 0,916, SIZE: 0,947 e ALCOHOL: 0,942) e, por sua vez, REPUTAT (reputação da marca) está associado a ambos fatores, apresentando cargas cruzadas (Fator 1: 0,511 e Fator 2: -0,533). A proporção acumulada que o modelo pode explicar permaneceu em 84,7% da variância total, demonstrando alta capacidade explicativa.

A variável REPUTAT, por apresentar carga cruzada, pode ser excluída para gerar um novo modelo fatorial. Esse procedimento foi realizado, mas a matriz de cargas fatoriais resultante mostrou que os fatores 1 e 2 foram significativos para todas as variáveis. Por essa razão, ela foi mantida na análise com uma interpretação prática que a associe a ambos os fatores. A decisão de mantê-la no modelo ocorreu devido ao seu MSA ser elevado (0,76).

A permanência dessa variável revela sua dupla natureza: enquanto se associa ao Fator 1 (atributos sensoriais: cor, aroma e sabor da bebida), refletindo a percepção de qualidade intrínseca da marca, também se relaciona ao Fator 2 (características quantitativas: preço, volume e teor alcoólico). Essa ambivalência indica que consumidores valorizam a reputação da marca tanto pela experiência sensorial quanto pela relação custo-benefício, por exemplo.

Além disso, com base nos dados apresentados na Tabela 5, observa-se que a variável REPUTAT está fundamentalmente alinhada com o Fator 1 (0,22), mostrando pouca relação com o Fator 2 (-0.03). Isso implica que a reputação da marca é construída principalmente sobre atributos sensoriais (cor, aroma e sabor), em vez de características quantitativas (preço, volume e teor alcoólico). Em resumo, ao avaliar uma marca, os consumidores tendem a valorizar mais a qualidade percebida e os aspectos sensoriais do produto, deixando em segundo plano os atributos puramente quantitativos ou funcionais.

Tabela 5: Matriz de Escores Fatoriais

Atributos Sensoriais e Características Quantitativas

VARIÁVEL	FATOR 1	FATOR 2
COST (custo do pack)	−0.17	0.28
SIZE (volume de cerveja no pack)	−0.20	0.26
ALCOHOL (percentagem de álcool na bebida)	−0.19	0.27
REPUTAT (reputação da marca)	0.22	−0.03
COLOR (cor da bebida)	−0.23	−0.22
AROMA (aroma da bebida)	−0.22	−0.23
TASTE (sabor da bebida)	−0.21	−0.25

Elaborado pelo autor.

Fonte: Dados fornecidos pelo *moodle* UFOP, 2025.

2. DIFICULDADES ENCONTRADAS

Inicialmente, a análise fatorial consirou a variável classificadora (GROUP) e a variável interpretável (SES). Isso afetou os resultados inferidos, alterou as interpretações desenvolvidas e dificultou a tomada de decisões. Tão logo, ambas variáveis foram removidas e todo o processo refeito sem muitos problemas. Além disso, buscou-se revisar materiais bibliográficos como forma de apoiar e direcionar o uso de técnicas, bem como para construir as análises em torno de cada processo.

REFERÊNCIAS

CARRER, C. C. **Caracterização e diferenciação regional da pecuária de corte no Brasil do fim do século: gênese, modernização e a reestruturação produtiva e mercadológica.** 2000. 268 f. Tese (Doutorado em Engenharia Agrícola) — Universidade Estadual de Campinas, Campinas, 2000.

HAIR JR., J.F.; WILLIAM, B.; BABIN, B.; ANDERSON, R.E. **Análise multivariada de dados.** 6.ed. Porto Alegre: Bookman, 2009.

MALHOTRA, N. K. **Pesquisa de marketing: uma orientação aplicada.** 3º ed. Porto Alegre: Bookman, 2001. 720p.